

A decorative graphic on the left side of the slide. It consists of a blue parallelogram and a light green parallelogram, both tilted at an angle. The blue shape is in the foreground, and the green shape is partially behind it. They are set against a dark blue background with faint, lighter blue diagonal stripes.

Prompt Engineering



Prompt Engineering

Tópicos abordados no capítulo:

- Introdução à engenharia de prompt e contexto.
- Melhores práticas de construção para prompts.
- Prompts defensivos e técnicas de defesa.



Introdução a engenharia prompt

O que é engenharia de prompt?

"O processo de montagem de instruções que permitem a um modelo gerar o resultado esperado."

"... guia o comportamento do modelo sem a necessidade de alterar os pesos do modelo."

"... é uma forma de comunicação Humano para IA."



Introdução ao prompt

O que é um prompt?

"Uma instrução dada a um modelo para realizar uma tarefa"

Consiste de uma estrutura composta de "descrição da tarefa", "exemplos" e "Tarefa"

IMPORTANTE: Prompts apenas funcionam se o modelo ser capaz de seguir instruções.

A robustez de um modelo para com prompts é definida pelo nível de perturbação medido ao se realizar algumas alterações no prompt. Ex: trocar "5" por "cinco" ou "Cinco"



Estrutura de um prompt

Descrição da tarefa:

O que o modelo deve fazer, incluindo a Persona do modelo e o formato de saída.

Exemplos:

Exemplos de entrada e suas respectivas saídas.

A tarefa:

A tarefa concreta, a pergunta a ser respondida.



Prompt de sistema e prompt de usuário

Prompt de sistema: Instruções providas por desenvolvedores de aplicação, contém instruções da descrição da tarefa e exemplos.

Prompt de usuário: Instruções providas por usuários, contém as instruções da tarefa.

"Muitos provedores de modelo dão ênfase no fato de que prompts de sistema bem construídos melhoram performance... mas como que isso ocorre visto que os prompts de sistema e usuário são concatenados em uma única mensagem?"

"Ou modelos são melhores para processar as instruções no início, ou foram pós-treinados para dar mais ênfase ao prompt de sistema"

IMPORTANTE: Diferentes modelos possuem templates de chat diferentes, verifique o template correto para o modelo que você está utilizando.



Contexto vs prompt

Normalmente, contexto e prompt são sinônimos.

Contexto pode ser entendido como toda a entrada do sistema, neste caso, podemos considerar contexto como o prompt.

Contexto também pode ser entendido como informação contextual, nesse sentido o contexto é uma parte do prompt que contém a informação necessária para resolver a tarefa.



In-context Learning

Ensinar o modelo como realizar uma tarefa através de prompts.

"In-context learning permite que o modelo incorpore novas informações continuamente para tomar decisões"

Pode ser *Zero-shot* ou *Few-shot*



Tamanho de contexto

O tamanho do contexto representa quanta informação pode ser adicionada no prompt.

Contexto MAIOR -> maior limite de resposta e maior limite para contexto.

O tamanho do contexto aumentou significativamente nos últimos anos.

"Pesquisas mostram que modelos são melhores no entendimento de instruções no início e no fim de um prompt"



Tamanho de contexto

O tamanho do contexto representa quanta informação pode ser adicionada no prompt.

Contexto MAIOR -> maior limite de resposta e maior limite para contexto.

O tamanho do contexto aumentou significativamente nos últimos anos.

"Pesquisas mostram que modelos são melhores no entendimento de instruções no início e no fim de um prompt"

"Se um contexto maior causa perda de performance, tente reduzir o seu prompt"



Melhores práticas de prompting

- Escreva instruções explícitas e concisas.
- Inclua contexto suficiente.
- Quebre tarefas complexas em subtarefas.
- Dê tempo para o modelo pensar (CoT).
- Iterar seus prompts.
- Avalie seus prompts com ferramentas.
- Organize e versione prompts.

As técnicas acima são técnicas gerais que funcionam para vários modelos e vão continuar relevantes.



Escreva instruções explícitas e concisas

- Explique sem ambiguidade o que você quer
 - Se deseja utilizar um sistema de *Score*, explique como o cálculo deve funcionar
- Utilize personas
 - Explique a perspectiva pela qual a IA deve visualizar a tarefa.
- Dê exemplos

Dicas:

Melhore seus prompts conforme percebe comportamentos indesejados.

Se desejar uma resposta concisa, diga isso ao modelo.

Para tarefas esperando saídas estruturadas utilize marcadores para delimitar onde a saída se inicia.



Inclua contexto suficiente

Ter a informação necessária para resolver um problema melhora a performance do modelo e auxilia na redução de alucinações.

"Se um modelo deve responder a um artigo, incluir o artigo no contexto pode melhorar consideravelmente a performance, ..., caso o modelo não receba o contexto necessário ele pode acabar utilizando apenas o seu conhecimento interno, o que pode causar mais alucinações"

O processo de coleta do contexto necessário é chamado de construção de contexto.

Ferramentas para construção de contexto são discutidas no Capítulo 6.



Quebre tarefas complexas em subtarefas

- Separar um grande prompt com várias etapas em vários prompts.
- Modelos ainda são melhores em entender instruções simples.
- Vantagens
 - Performance melhor
 - Monitoração
 - Debug
 - Paralelização
 - Esforço menor
- Desvantagens
 - Latência maior
 - Complexidade maior



Dê tempo para o modelo pensar

Chain-of-thought:

Exija um pensamento passo a passo ou motivo da decisão, isso faz com que o modelo pense mais profundamente sobre o problema.

Self-critique:

Exija que o modelo valide sua saída, também chamado de *self-eval*, faz o modelo pensar criticamente sobre o problema



Iterar seus prompts

- Revise seus prompts conforme avalia os resultados gerados.
 - Prompts diferentes
 - Modelos diferentes
 - Organize diferente
- Estabeleça métricas padrões para comparar performance.
- "Prompts devem ser avaliados em perspectiva de sistema, um prompt pode melhorar a performance de uma tarefa, mas piorar a performance do sistema."



Avalie ferramentas de engenharia de prompt

Ferramentas que buscam otimizar prompts, buscam os prompts mais performáticos para realizar uma determinada tarefa a partir da especificação da entrada + saída que melhor se adequa a um determinado dataset de avaliação (Ex: OpenPrompt e DSPy).

Outra forma de criar e otimizar prompts é utilizar o próprio modelo, solicitando que ele crie, otimize ou critique seu prompt.

Deepmind Promptbreeder: Cria prompts através de um processo evolucionário.

IMPORTANTE:

Cuidado com custos utilizando IA para melhorar prompts.

Mantenha os prompts simples até que por necessidade eles exijam maior complexidade.



Organize e versione prompts

- Separe prompts do código da aplicação
 - Reusabilidade
 - Testabilidade
 - Colaboração
- Versione seus prompts e use metadados para especificar o uso
- Utilizar ferramentas como git para controle de versão e catálogo de prompts



Engenharia de prompt defensivo

Principais ataques de prompt:

- *Prompt Extraction*
- *Jailbreaking*
- *Information extraction*

Riscos de ataques de prompt:

- *Remote code or tool execution*
- *Data leaks*
- *Misinformation*
- *Service interruption*
- *Brand risk*



Engenharia reversa de prompts

A dificuldade para criar um prompt torna este um recurso valioso.

Engenharia reversa de prompt é o processo de descobrir o prompt de sistema da aplicação, com o intuito de revender ou manipular de maneira indevida.

Consiste em analisar a saída do modelo ou enganar o modelo para que ele revele seu prompt de sistema.



Jailbreaking e Prompt Injection

"*Jailbreaking* consiste em burlar funcionalidades de segurança do modelo."

"*Prompt Injection* refere-se a um tipo de ataque onde instruções maliciosas são injetadas no prompt"

Formas de ataque:

- *Direct manual prompt hacking*
- *Automated attacks*
- *Indirect prompt injection*



Information Extraction

Information Extraction busca descobrir as informações que o modelo foi treinado ou o seu acesso à informação, exemplos de extração:

- *Data leak*
- *Privacy violation*
- *Copyright infringement*

O modelo "*memoriza*" algumas informações.

"As mesmas técnicas utilizadas para avaliar o conhecimento de um modelo podem ser utilizadas para extrair informações sensíveis"



Defesas contra ataques de prompts

- Comece entendendo os tipos de ataque que sua aplicação pode receber.
- Avaliar com base em *violation rate* e *false refusal rate*.
- *Model-level defense*.
- *Prompt-level defense*.
 - Duplicação.
 - Ignorar modos de ataque conhecidos.
- *System-level defense*.
 - Utilizar contexto isolado.
 - Exigir autorização para comandos de alto impacto.
 - Definir Assuntos fora de tópico.
 - Utilizar IA para avaliação de intenção.
 - *Guardrails* na entrada e na saída.